Assignment 1 Report

Task 1. `LogMelFilterBanks`

В работе реализован слой `LogMelFilterBanks` на `torch` без использования готового `MelSpectrogram` внутри самого слоя.

Слой включает следующие этапы:

- вычисление STFT через `torch.stft`
- получение спектральной мощности
- проекцию на mel-шкалу через `torchaudio.functional.melscale_fbanks`
- логарифмирование `log(x + 1e-6)`

Корректность реализации была проверена сравнением с `torchaudio.transforms.MelSpectrogram` с последующим логарифмированием. Проверка показала совпадение формы выходов и численных значений.

Task 2. Binary Classification Model

Для обучения использовался датасет `Speech Commands`. Исходная задача была сведена к бинарной классификации:

- `yes -> 1`
- `no -> 0`

Использовались стандартные разбиения датасета:

- `training`
- `validation`
- `testing`

В качестве модели использовалась компактная `Conv1d` CNN:

- входом служат признаки `LogMelFilterBanks`
- далее применяются несколько `Conv1d` блоков с `BatchNorm1d`, `ReLU` и `MaxPool1d`
- на выходе используется `AdaptiveAvgPool1d` и полносвязный классификатор

В ходе экспериментов сохранялись:

- `validation_accuracy`
- `test_accuracy`
- время эпохи
- число параметров
- FLOPs

Все полученные модели удовлетворяют ограничению задания:

- число параметров во всех конфигурациях меньше `100000`

Full Grid Search

Для анализа качества и вычислительной эффективности был проведён полный перебор конфигураций:

- `n_mels in [20, 40, 80]`
- `groups in [1, 2, 4, 8, 16]`

Невалидные комбинации, которые были пропущены:

- `(20, 8), (20, 16), (40, 16)`

Сводные результаты:

n_mels	groups	params	FLOPs	test accuracy	mean epoch time, s
20	1	48930	7279266	0.9879	6.86
20	2	26274	3642786	0.9600	6.39
20	4	14946	1824546	0.9563	6.38
40	1	55330	8572066	0.9806	6.47
40	2	29474	4289186	0.9794	6.58
40	4	16546	2147746	0.9745	6.56
40	8	10082	1077026	0.9515	6.52
80	1	68130	11157666	0.9769	6.53
80	2	35874	5581986	0.9454	6.52
80	4	19746	2794146	0.9745	6.50
80	8	11682	1400226	0.9417	6.57
80	16	7650	703266	0.9551	6.54

Graphs for `groups`

Графики ниже построены для среза `n_mels = 80`.

Epoch Training Time vs Groups

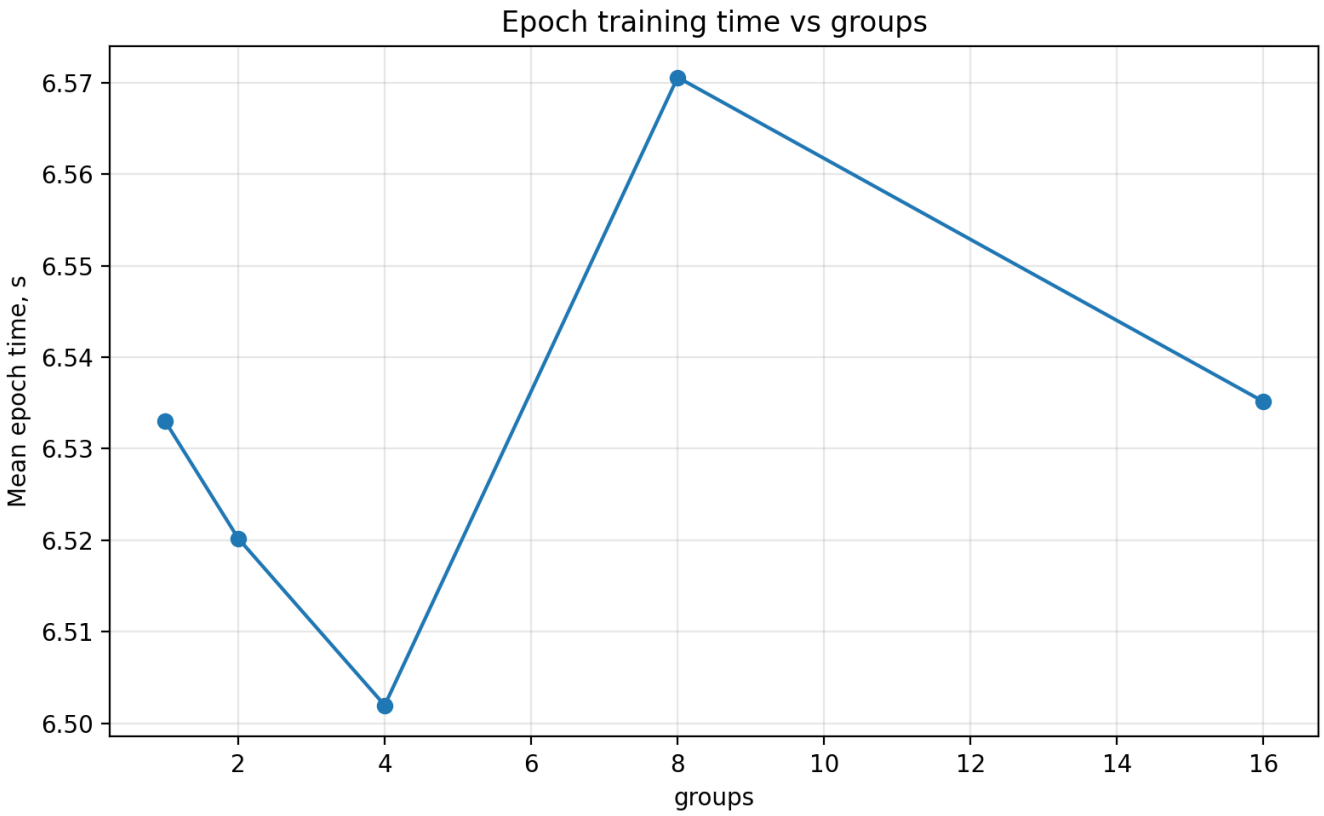

Parameters vs Groups

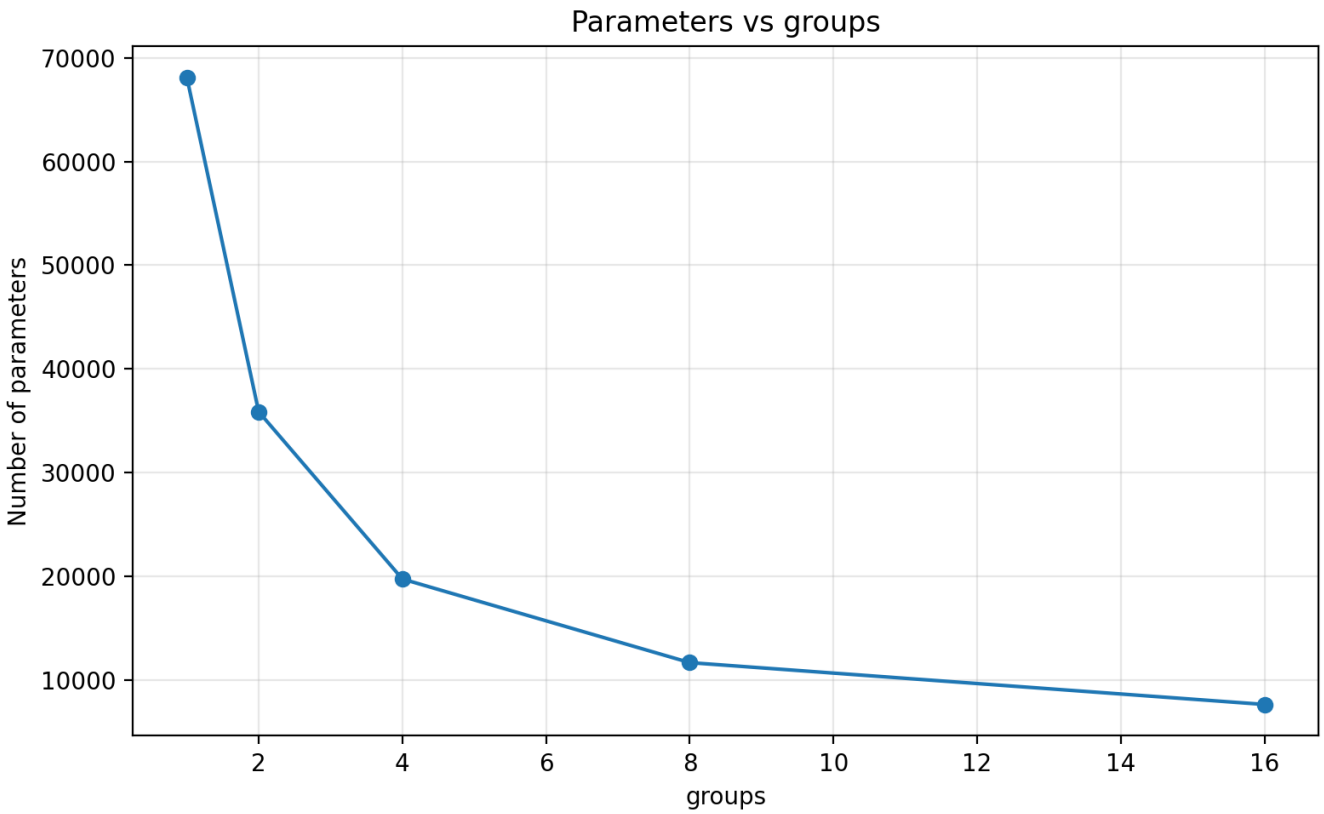

FLOPs vs Groups

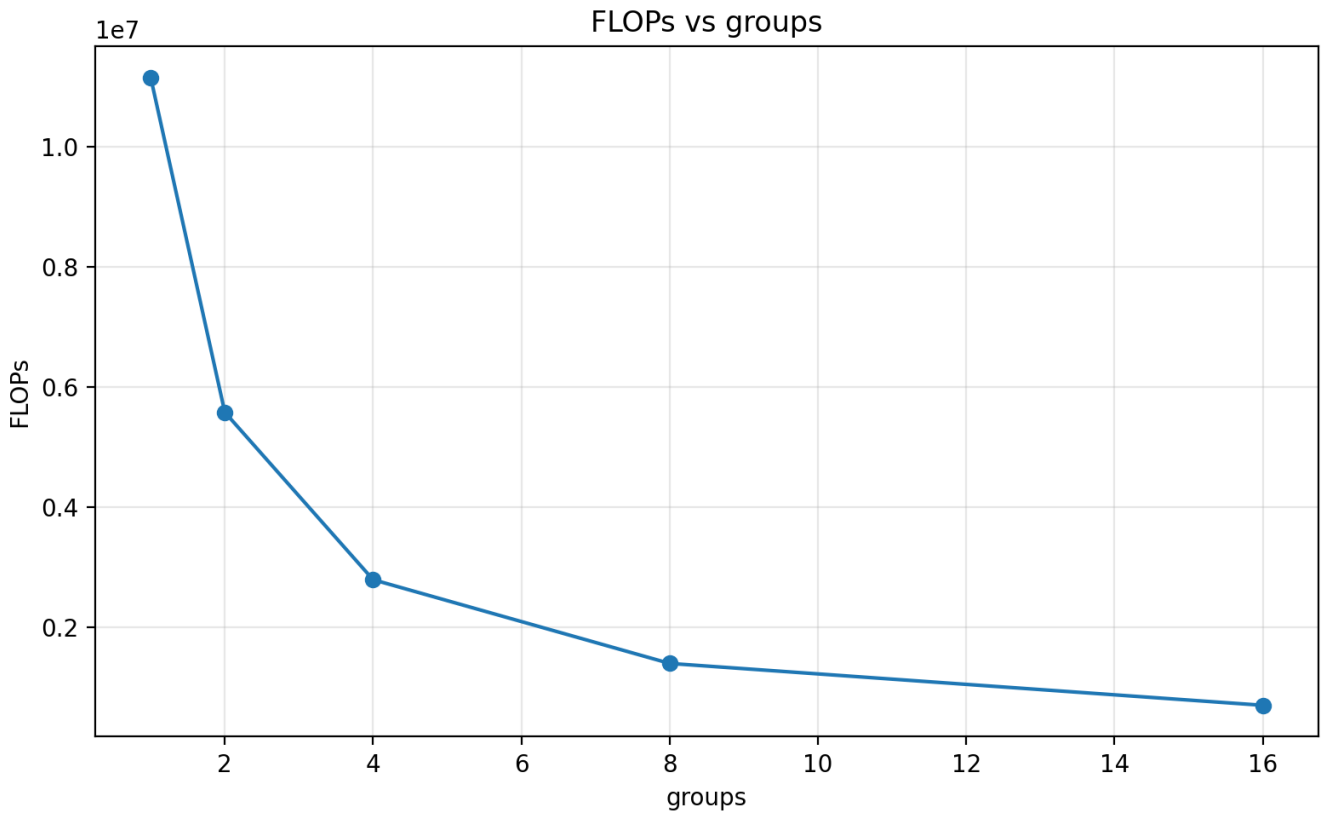

Test Accuracy vs Groups

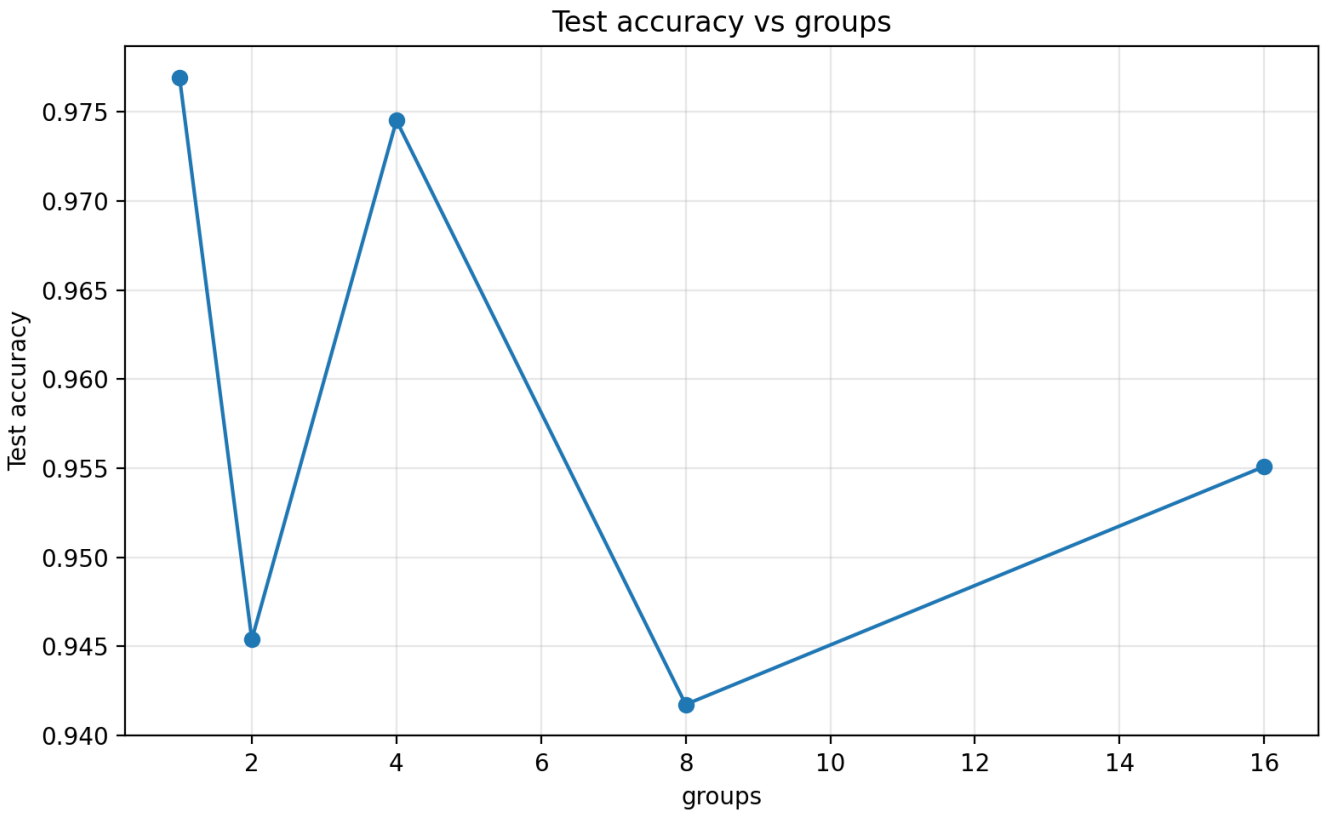

Graphs for `n_mels`

Графики ниже построены для среза `groups = 1`.

Epoch Training Time vs n_mels

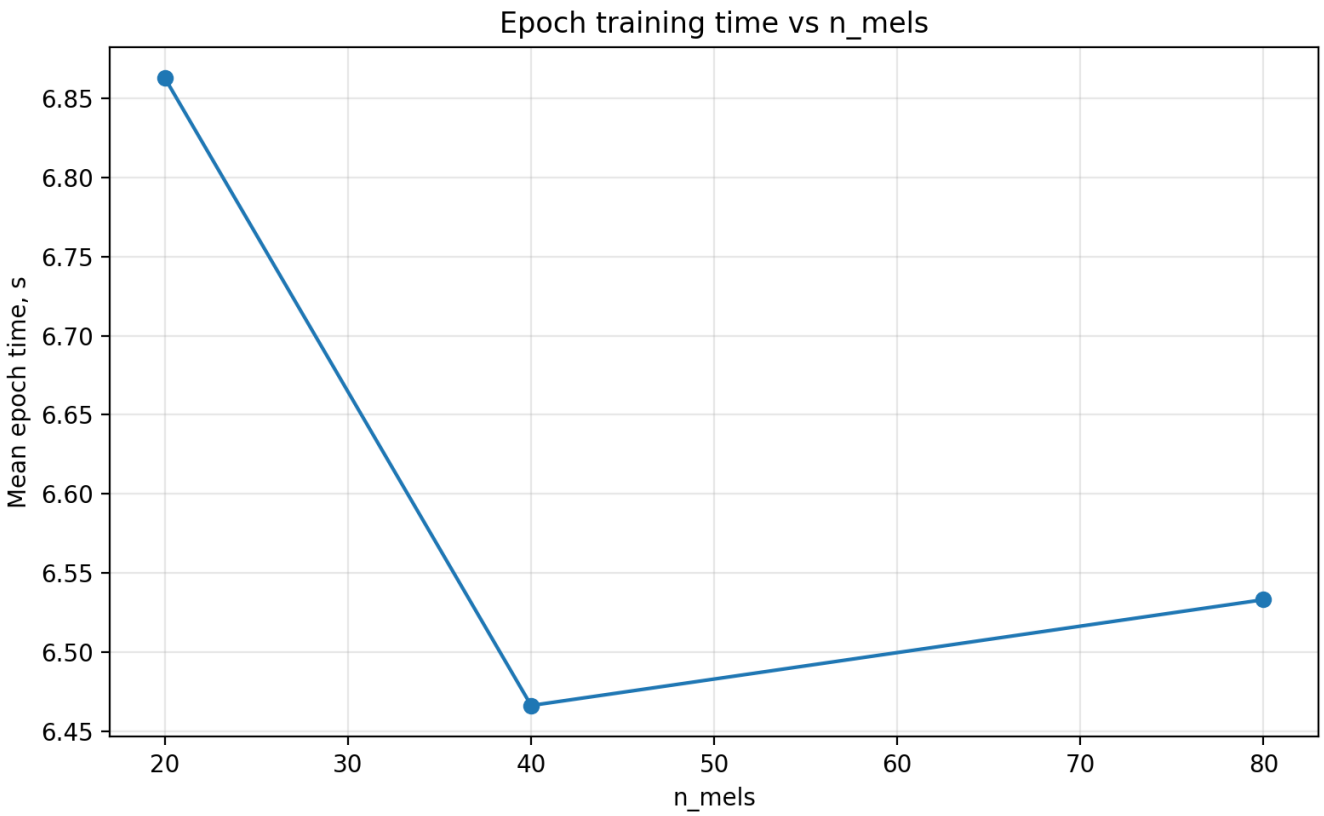

Parameters vs n_mels

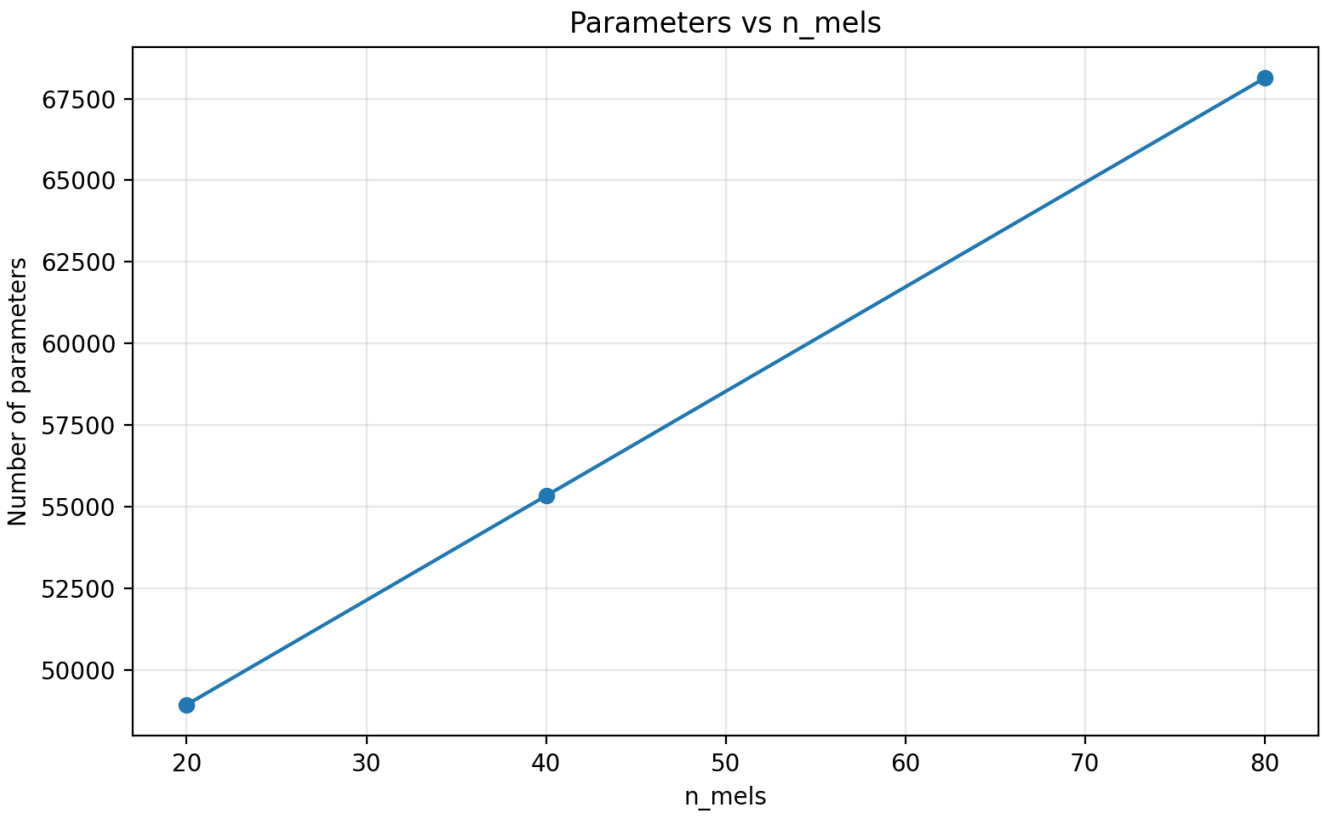

FLOPs vs n_mels

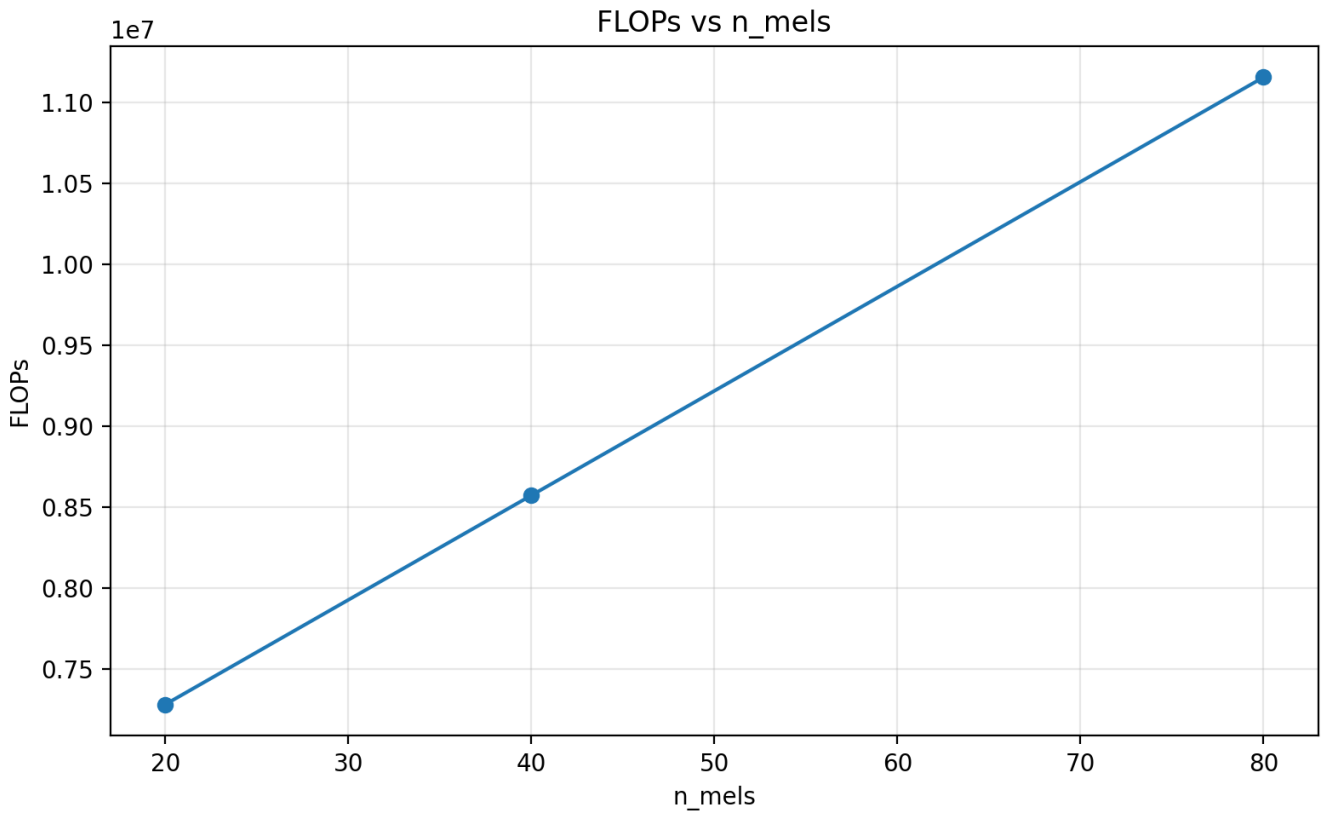

Test Accuracy vs n_mels

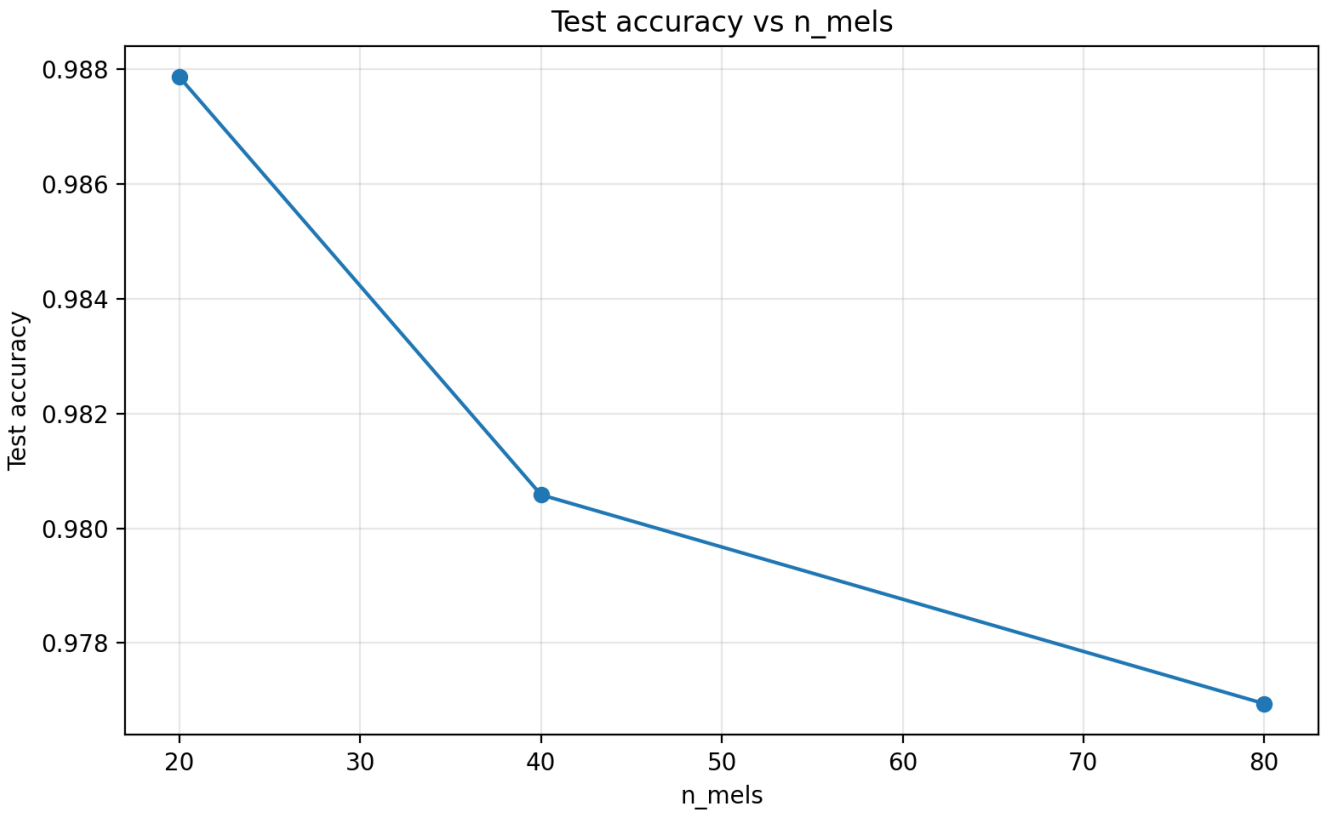

Quality Across Full Grid

Test Accuracy Heatmap

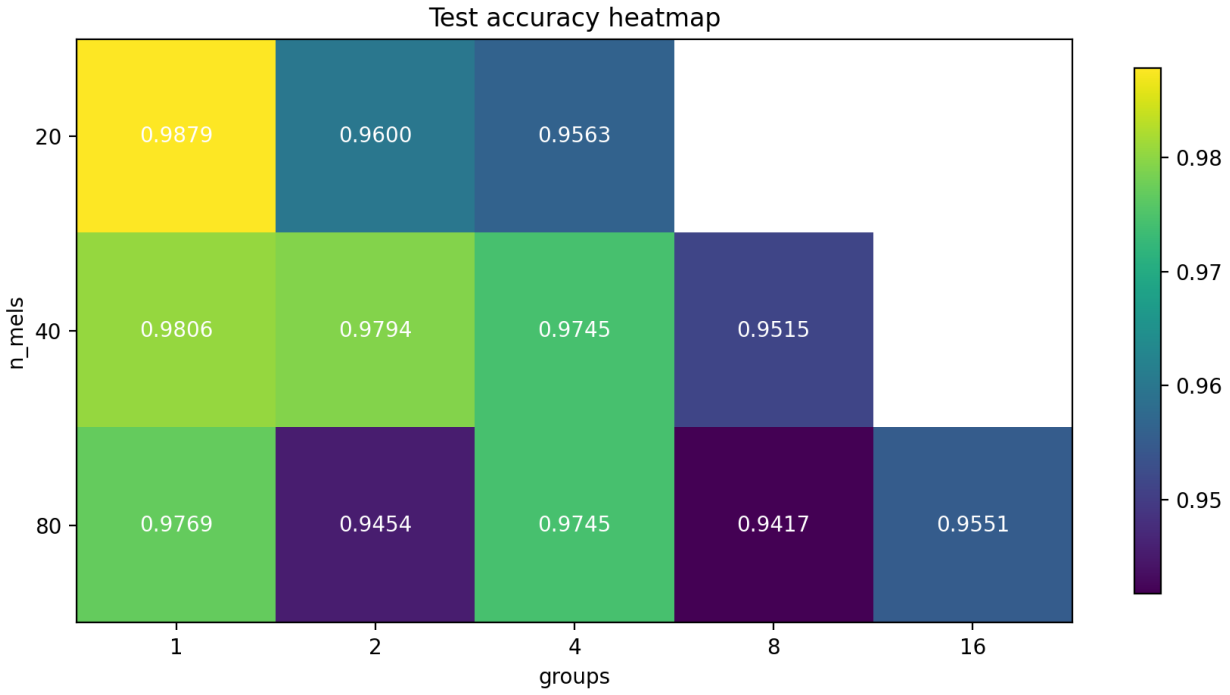

Test Accuracy vs Groups by n_mels

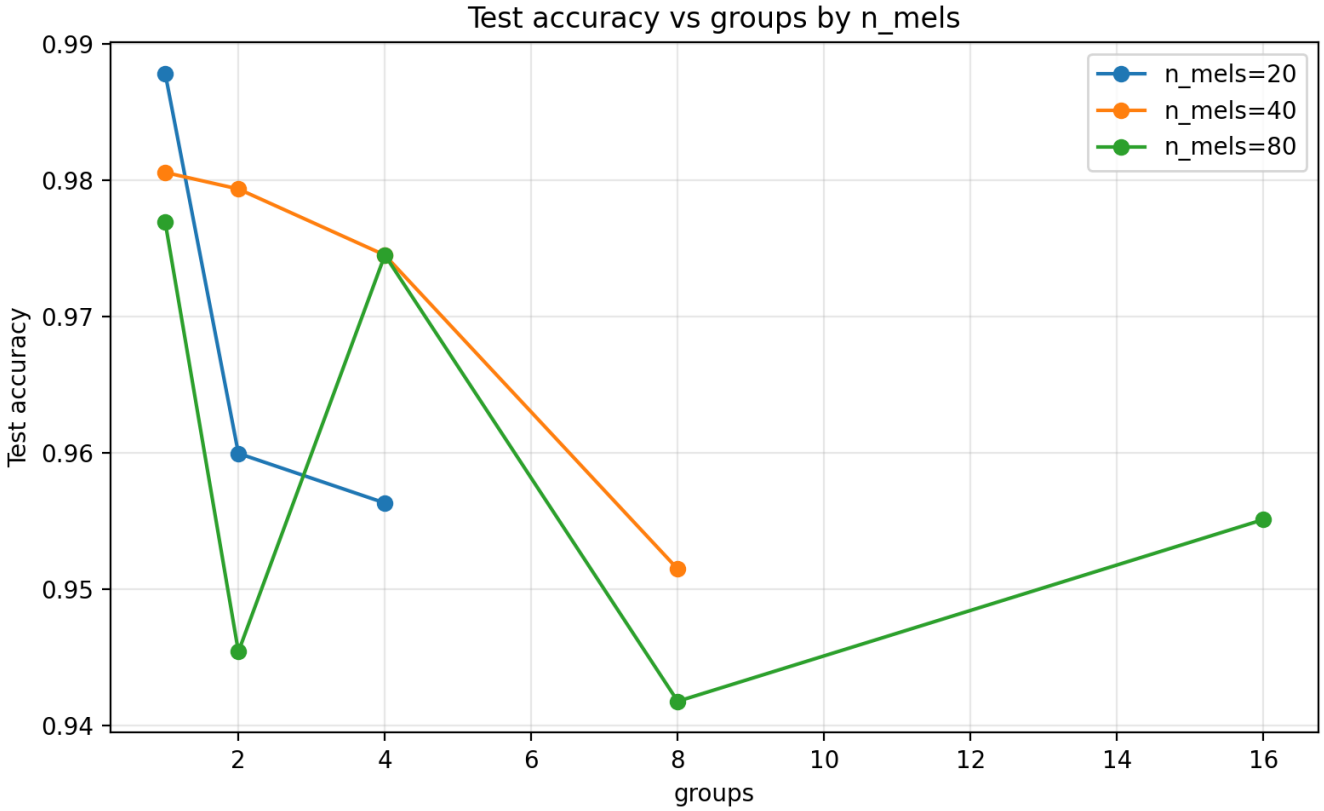

Test Accuracy vs n_mels by groups

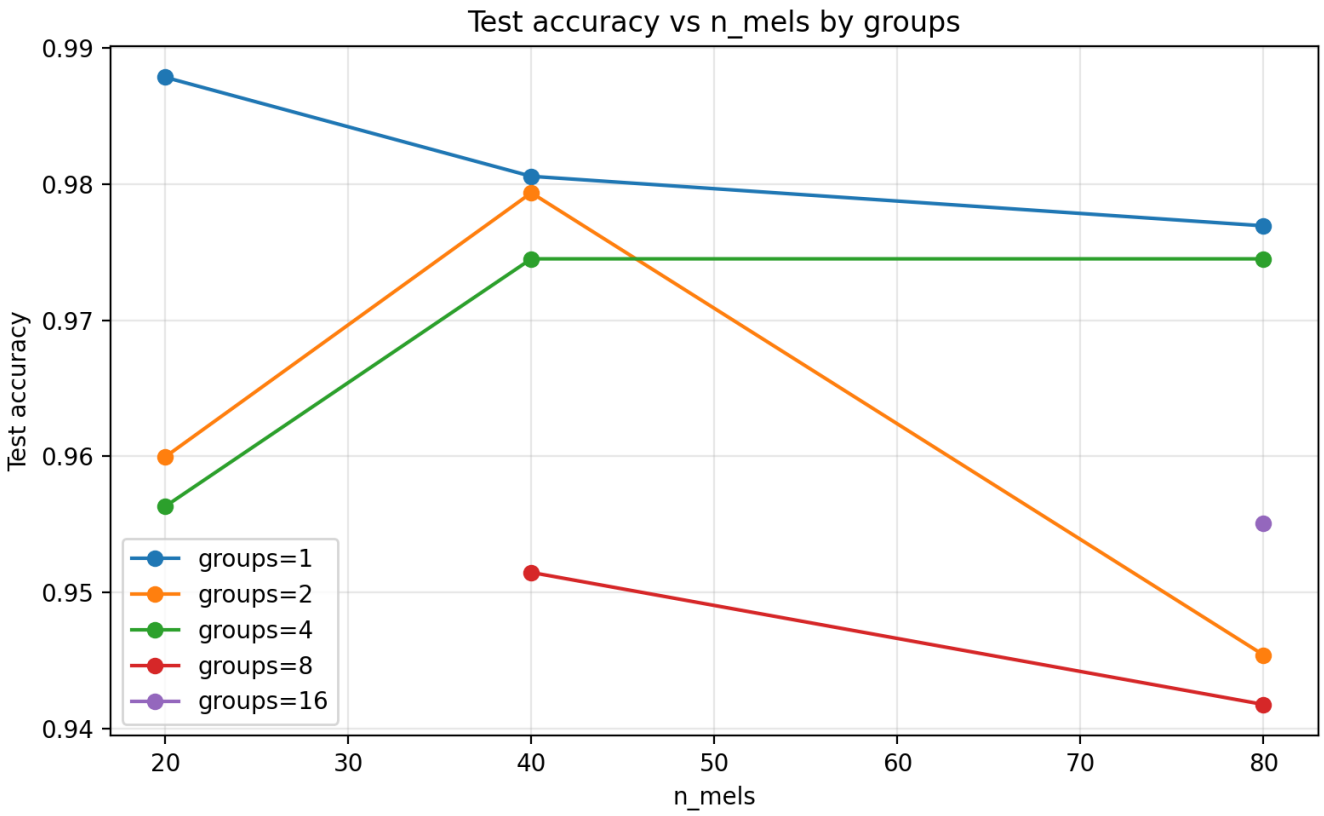

Analysis of `n_mels`

Для анализа влияния числа mel-фильтробанков сравним конфигурации при `groups = 1`.

n_mels	params	FLOPs	test accuracy	mean epoch time, s
20	48930	7279266	0.9879	6.86
40	55330	8572066	0.9806	6.47
80	68130	11157666	0.9769	6.53

Выводы по `n_mels`:

- лучшая точность получена при `n_mels = 20`
- увеличение `n_mels` ведёт к росту числа параметров и FLOPs
- в данной бинарной задаче большее число mel-фильтров не дало улучшения качества

Analysis of `groups`

Для анализа влияния grouped convolution сравним конфигурации при `n_mels = 80`.

groups	params	FLOPs	test accuracy	mean epoch time, s
1	68130	11157666	0.9769	6.53
2	35874	5581986	0.9454	6.52
4	19746	2794146	0.9745	6.50
8	11682	1400226	0.9417	6.57
16	7650	703266	0.9551	6.54

Выводы по `groups`:

- увеличение `groups` монотонно уменьшает число параметров и FLOPs
- наилучшее качество в этом срезе достигается при `groups = 1`
- конфигурация `groups = 4` даёт лучший компромисс между качеством и вычислительной стоимостью
- слишком большие значения `groups` ухудшают итоговую точность заметнее

Chosen Baseline

В качестве baseline для следующего этапа выбрана конфигурация:

- `n_mels = 20`
- `groups = 1`

Характеристики baseline:

- `test_accuracy = 0.9879`
- `num_parameters = 48930`
- `FLOPs = 7279266`

Эта модель показывает лучший результат по качеству и уверенно укладывается в ограничение по числу параметров.

Conclusion

В работе был реализован собственный слой `LogMelFilterBanks` и обучена компактная `Conv1d` CNN для бинарной классификации команд `yes/no` из датасета Speech Commands.

Итоговые выводы:

- реализация `LogMelFilterBanks` работает корректно
- для данной задачи оптимальным значением оказалось `n_mels = 20`
- параметр `groups` позволяет значительно уменьшать модель и вычислительную сложность
- лучшим компромиссом по эффективности оказался `groups = 4`
- наилучший общий результат показала конфигурация `n_mels = 20`, `groups = 1`